



**UNIVERSIDAD
DE LA RIOJA**



**FUNDACIÓN
UNIVERSIDAD
DE LA RIOJA**

**MÁSTER EN GRANDES MODELOS DE LENGUAJE Y
LINGÜÍSTICA COMPUTACIONAL**

**“De Corpus A Grafo: Un Enfoque Basado En
Grafos De Conocimiento Para El Estudio De La
Adaptación Al Cambio Climático”**

Autor: María Ayelén Cura

Tutor académico: Matías Nuñez

Curso Académico: Marzo 2025 – Enero 2026.

Resumen

Este Trabajo Fin de Máster presenta un enfoque computacional para el análisis de la adaptación al cambio climático basado en la construcción y explotación de grafos de conocimiento derivados de corpus científicos extensos. El objetivo principal es evaluar el potencial de los grafos de conocimiento, combinados con técnicas de procesamiento del lenguaje natural y modelos de lenguaje de gran escala, para estructurar información compleja y favorecer un razonamiento relacional más profundo en comparación con métodos tradicionales de recuperación textual.

La metodología se articula en cuatro fases. En primer lugar, se construyó un corpus multidisciplinar sobre adaptación al cambio climático a partir de literatura científica revisada por pares e informes institucionales, siguiendo criterios de relevancia temática y diversidad conceptual. En segundo lugar, se diseñó una ontología de dominio que formaliza las principales entidades y relaciones del ámbito de estudio, incluyendo peligros climáticos, impactos, medidas de adaptación, sectores afectados y grupos sociales vulnerables. En la tercera fase, la ontología fue instanciada mediante la construcción de un grafo de conocimiento semiautomático, que permitió transformar la información textual en una estructura relacional explícita y coherente. Finalmente, el grafo fue evaluado experimentalmente mediante un enfoque de Retrieval-Augmented Generation con búsqueda estructural (GraphRAG), comparando su desempeño con esquemas de recuperación plana.

Los resultados obtenidos muestran que la búsqueda estructural basada en grafos proporciona respuestas más contextualizadas y explicativas, especialmente en consultas complejas que requieren integrar múltiples dimensiones socioeconómicas, territoriales y ambientales. Asimismo, los experimentos evidencian una mayor capacidad para identificar relaciones indirectas y cadenas causales relevantes.

Como conclusión, este trabajo demuestra que los grafos de conocimiento constituyen una herramienta metodológica sólida para el estudio de la adaptación al cambio climático, siempre que su construcción vaya acompañada de un control ontológico riguroso y procesos iterativos de validación semántica.

Índice

Contents

Resumen 2

CAPITULO I: METODOLOGIA..... 4

CAPITULO II: PARTE ANALÍTICA DE TRATAMIENTO DE DATOS..... 7

Fase I: la cacería documental y la ingeniería del corpus 7

Fase II: La Ontología o la Gramática del Mundo 11

Fase III: la alianza con los LLMs y la construcción del grafo..... 21

Fase IV: Experimentos con Retrieval-Augmented Generation (GraphRAG) 27

CONCLUSIONES 37

Bibliografía (formato APA)..... 39

Anexo I..... 40

CAPITULO I: METODOLOGIA

Introducción

En los últimos años, la investigación sobre el cambio climático ha incorporado de manera creciente enfoques computacionales orientados a la integración, estructuración y análisis de grandes volúmenes de información heterogénea. En particular, el uso de corpus textuales extensos combinados con técnicas de procesamiento del lenguaje natural (PLN), modelos de lenguaje de gran escala (LLM) y grafos de conocimiento se ha consolidado como una estrategia metodológica relevante para el estudio de fenómenos complejos, como las medidas de adaptación al cambio climático y sus impactos sociales, territoriales y sectoriales.

Este trabajo se inscribe en dicha línea metodológica y se desarrolló de manera colaborativa, mediante un proceso grupal iterativo que permitió distribuir tareas, contrastar decisiones conceptuales y refinar progresivamente los resultados. La metodología adoptada se estructura en cuatro fases principales: (i) construcción del corpus, (ii) diseño de la ontología, (iii) construcción del grafo de conocimiento y (iv) experimentación analítica mediante GraphRAG.

Descripción general del enfoque metodológico

La primera fase consistió en la construcción de un corpus textual representativo del dominio de la adaptación al cambio climático. Siguiendo prácticas ampliamente documentadas en la literatura, se priorizó la selección de fuentes científicas revisadas por pares, complementadas con informes institucionales y literatura gris relevante. El proceso de recopilación se realizó de forma iterativa, mediante el uso de bloques conceptuales y cadenas de búsqueda progresivamente refinadas, con el objetivo de equilibrar cobertura temática y relevancia del contenido. El corpus resultante constituye la base empírica del trabajo y permite capturar la naturaleza multidimensional del fenómeno, incluyendo peligros climáticos, medidas de adaptación, sectores afectados, escalas geográficas y grupos sociales vulnerables.

El diseño de la ontología fue la fase siguiente, a partir del corpus construido. Se desarrolló una ontología de dominio que actúa como núcleo semántico del sistema. Esta fase se centró en la identificación y formalización de las principales entidades y relaciones presentes en los textos, tales como *climate hazards*, *adaptation measures*, *socioeconomic factors*, *affected sectors* y *vulnerable groups*. El diseño ontológico se llevó a cabo de manera colaborativa, combinando revisión manual del corpus con apoyo de modelos de lenguaje para la identificación de patrones conceptuales recurrentes. La ontología resultante permite explicitar supuestos conceptuales y establecer un marco estructurado que guía tanto la construcción del grafo como los posteriores procesos de consulta y análisis, en línea con definiciones clásicas de ontología como especificación formal de un dominio conceptual (Gruber, 1993).

La tercera fase del trabajo se orientó a la construcción del grafo de conocimiento a partir de la ontología definida y del corpus seleccionado. En esta etapa, los conceptos ontológicos fueron instanciados mediante la identificación sistemática de entidades relevantes y de vínculos semánticos presentes en los textos, permitiendo transformar la información no estructurada en una representación relacional explícita. Este proceso posibilitó la integración de fenómenos climáticos, factores socioeconómicos, medidas de adaptación y contextos territoriales dentro de una misma estructura formal.

La construcción del grafo se realizó mediante un enfoque semiautomático que combinó técnicas de procesamiento del lenguaje natural asistidas por modelos de lenguaje con criterios de validación conceptual. Los modelos se emplearon para detectar patrones semánticos recurrentes y proponer relaciones entre los conceptos, atendiendo al contexto discursivo en el que aparecen. Estas propuestas fueron posteriormente revisadas y ajustadas de forma iterativa, con el objetivo de asegurar la coherencia interna del grafo y su alineación con la ontología del dominio de adaptación al cambio climático. Finalmente, el grafo fue sometido a sucesivas etapas de depuración y refinamiento, orientadas a evaluar la pertinencia semántica de los nodos y relaciones, así como a reducir redundancias y relaciones excesivamente genéricas. Este proceso permitió consolidar una estructura relacional capaz de representar dependencias directas e indirectas entre los distintos componentes del dominio, sentando las bases para su

posterior análisis y validación mediante enfoques de recuperación y generación basados en grafos.

La última fase, experimentación con GraphRAG, combinó recuperación de información basada en grafos con generación de lenguaje natural. Esta fase tuvo como objetivo evaluar la calidad, coherencia y profundidad explicativa del grafo mediante consultas complejas, así como analizar su comportamiento frente a variaciones léxicas y estructurales. La experimentación permitió contrastar búsquedas planas tradicionales con búsquedas estructurales sobre el grafo, aportando evidencia empírica sobre el valor añadido del conocimiento explícitamente modelado frente a la recuperación textual convencional (Lewis et al., 2020). En conjunto, la metodología adoptada articula prácticas consolidadas de construcción de corpus y modelado ontológico con técnicas recientes de razonamiento asistido por grafos y LLM, permitiendo no solo la estructuración del conocimiento sobre adaptación al cambio climático, sino también su análisis crítico y validación experimental.

CAPITULO II: PARTE ANALÍTICA DE TRATAMIENTO DE DATOS

Fase I: la cacería documental y la ingeniería del corpus

Objetivo de la fase

El objetivo de esta primera fase fue la construcción de un corpus textual amplio, heterogéneo y representativo del dominio de la adaptación al cambio climático, que sirviera como base empírica para la posterior inducción de una ontología y la construcción de un grafo de conocimiento. Para ello, se adoptó un enfoque iterativo orientado a maximizar la cobertura temática sin comprometer la calidad y relevancia de los documentos recopilados.

Enfoque general y criterios metodológicos

La construcción del corpus se abordó desde una perspectiva exploratoria inicial, seguida de un proceso progresivo de refinamiento. En línea con metodologías recientes en lingüística computacional aplicada al análisis climático, se priorizó la integración de fuentes científicas e institucionales de alta autoridad, combinadas mediante un pipeline común de recolección, normalización y deduplicación.

Se establecieron como criterios principales: la relevancia temática para la adaptación al cambio climático, diversidad de fuentes y tipos documentales, posibilidad de segmentación y procesamiento automático, y trazabilidad y reproducibilidad del proceso de recolección.

Selección y ampliación de fuentes

El corpus se construyó a partir de la integración de múltiples fuentes, seleccionadas por su relevancia y complementariedad:

- IPCC (Intergovernmental Panel on Climate Change), como principal referencia científica en cambio climático.

- UNDRR (United Nations Office for Disaster Risk Reduction), orientada a riesgos, desastres y resiliencia.
- Banco Mundial, con énfasis en desarrollo, vulnerabilidad y adaptación climática.
- Bases de datos científicas como arXiv, Semantic Scholar y OpenAlex.

Durante el proceso se amplió progresivamente el conjunto de fuentes, siguiendo las actividades propuestas en el *notebook_01_corpus_clima_taxonomía ampliada.ipynb* del curso, ubicado en *Anexo I*, incorporando nuevas APIs y repositorios institucionales. Esta ampliación permitió enriquecer el corpus tanto en volumen como en diversidad temática y geográfica.

Diseño de las cadenas de búsqueda y bloques conceptuales

La recuperación de documentos se realizó mediante la definición de bloques conceptuales lógicos, siguiendo un esquema de intersección semántica:

- Bloque de fenómeno: términos asociados a peligros climáticos (por ejemplo, *flood*, *drought*, *heatwave*).
- Bloque de acción: términos vinculados a adaptación y resiliencia (por ejemplo, *adaptation*, *resilience*).
- Bloque de solución: términos relacionados con medidas específicas (por ejemplo, *measure*, *infrastructure*).

La combinación de estos bloques mediante operadores lógicos permitió reducir el ruido y obtener un conjunto de documentos de alta relevancia para el objetivo del estudio. Este enfoque facilitó el paso desde una exploración amplia del dominio hacia subconjuntos de estudios de caso más manejables.

Integración y normalización del corpus

Los documentos recuperados desde las distintas fuentes fueron integrados en un único pipeline de procesamiento. Este pipeline incluyó la normalización de metadatos, eliminación de duplicados mediante identificadores persistentes (DOI, OpenAlex ID, entre otros) y la unificación de formatos y estructuras internas.

Cabe destacar que las bases consultadas son dinámicas y se actualizan de forma continua. En consecuencia, ejecuciones idénticas de las mismas consultas en distintos momentos temporales pueden producir variaciones en el número de documentos recuperados. Este fenómeno fue documentado y controlado mediante el registro de fechas de consulta y la fijación de ventanas temporales cuando fue necesario.

Procesamiento incremental de documentos extensos

Uno de los principales desafíos del armado del corpus fue el procesamiento de documentos extensos, particularmente los informes del IPCC. Debido a las limitaciones de memoria de los entornos de ejecución utilizados, se adoptó un enfoque de procesamiento incremental, en el cual cada documento o capítulo se descarga, procesa y segmenta de forma independiente.

Este enfoque permitió: liberar memoria tras cada etapa de procesamiento, evitar reinicios completos del pipeline, reanudar automáticamente el proceso mediante checkpoints en caso de interrupciones.

La segmentación de los informes en capítulos y secciones temáticas generó unidades documentales más manejables y adecuadas para el análisis posterior.

Estadísticas generales del corpus

Como resultado del proceso de integración y depuración de fuentes múltiples, el corpus final obtenido está compuesto por un total de 2.877 documentos únicos. Durante la fase de integración se procesaron inicialmente 2.889 documentos, de los cuales 12 fueron identificados y eliminados como duplicados, tras la aplicación de criterios de deduplicación basados en identificadores persistentes y coincidencias de metadatos.

El corpus resultante integra documentos procedentes de diversas fuentes científicas e institucionales, lo que garantiza tanto la diversidad temática como la complementariedad de enfoques. El desglose final por fuente es el siguiente:

- arXiv: 774 documentos añadidos, sin duplicados detectados.
- Semantic Scholar: 99 documentos añadidos, con 1 duplicado eliminado.

Commented [mc1]: Agregar figuras del notebook 01

Commented [mc2R1]: Extract wordcloud, and corpus distribution: pie and bar charts

- OpenAlex: 497 documentos añadidos, con 5 duplicados eliminados.
- Climate-ADAPT: 747 documentos añadidos, con 3 duplicados eliminados.
- Banco Mundial: 200 documentos añadidos, sin duplicados detectados.
- UNDRR: 163 documentos añadidos, sin duplicados detectados.
- IPCC: 397 documentos añadidos, con 3 duplicados eliminados.

La integración de estas fuentes permitió construir un corpus equilibrado entre literatura científica revisada por pares, literatura gris e informes institucionales de alta autoridad. Asimismo, el proceso de deduplicación contribuyó a mejorar la calidad del corpus, evitando la sobre-representación de documentos y garantizando una base empírica sólida para las fases posteriores de inducción ontológica y construcción del grafo de conocimiento. Cabe señalar que los resultados reflejan el estado de las bases de datos consultadas en el momento de ejecución del pipeline, dado el carácter dinámico de las APIs utilizadas.





Figura 1: resultados del análisis del corpus por año y tipo de Fuente.

 Gráfico guardado en data/corpus_clima/corpus_distribution.png

Síntesis de la fase

En esta primera fase se logró construir un corpus robusto y escalable, capaz de sustentar las etapas posteriores de inducción ontológica y construcción del grafo de conocimiento. El enfoque adoptado, basado en la integración de fuentes heterogéneas, el uso de bloques conceptuales y el procesamiento incremental, permitió equilibrar amplitud temática y viabilidad computacional, sentando las bases metodológicas del trabajo.

Fase II: La Ontología o la Gramática del Mundo

Objetivo de la fase ontológica

El objetivo de esta segunda fase fue la construcción de una ontología que permitiera formalizar y estructurar el conocimiento extraído del corpus sobre medidas de adaptación al cambio climático. Esta ontología constituye el núcleo semántico del grafo de conocimiento y define la “gramática del mundo” que hace posible la organización, consulta e interpretación de la información contenida en los documentos analizados.

A diferencia de enfoques ontológicos tradicionales basados exclusivamente en modelado manual, esta fase adoptó una metodología experimental apoyada en modelos de lenguaje de gran escala (LLMs), con el propósito de evaluar su capacidad para inducir estructuras conceptuales reutilizables y trazables directamente a partir de textos científicos.

Enfoque metodológico general

La construcción de la ontología se abordó como un proceso iterativo de descubrimiento, validación y refinamiento, combinando intervención humana y asistencia automática mediante LLMs. El enfoque se basó en dos principios fundamentales. Por un lado, el principio de evidencia textual explícita, es decir, que toda clase o relación debía estar respaldada por el contenido del corpus, sin introducir conocimiento externo no mencionado en los textos; por otra parte, el principio de la parsimonia y reutilización donde se priorizaron conceptos estables y recurrentes, evitando la inflación ontológica y la inclusión de entidades excesivamente específicas.

Este enfoque se alinea con prácticas recientes en la inducción ontológica para grafos de conocimiento, donde el énfasis se desplaza desde la exhaustividad hacia la utilidad para tareas de recuperación y análisis transversal.

Prompt DEBUG: inducción ontológica con trazabilidad

El *prompt DEBUG* fue diseñado como una herramienta diagnóstica y pedagógica. Su finalidad no fue producir directamente la ontología final, sino permitir identificar clases y relaciones candidatas; detectar sobreinterpretaciones o “clases fantasma” generadas por los LLMs; analizar la coherencia entre conceptos, relaciones y evidencia textual; y documentar explícitamente por qué ciertos elementos eran incluidos o rechazados.

Este prompt exigía que cada clase y relación estuviera acompañada de referencias a los abstracts que la sustentaban; fragmentos textuales específicos; y una justificación explícita de su inclusión.

De este modo, el *prompt DEBUG*, ubicado en *Anexo I*, permitió evaluar críticamente las capacidades y limitaciones de distintos modelos de lenguaje en tareas de inducción ontológica, así como refinar los criterios antes de consolidar la ontología.

Experimentos con múltiples modelos de lenguaje

Con el fin de evaluar la robustez del enfoque, se realizaron experimentos utilizando distintos LLMs, entre ellos ChatGPT, Gemini, Claude, Copilot y DeepSeek. Los experimentos se llevaron a cabo tanto con el *prompt DEBUG* como con variantes refinadas del *prompt*. Dado el tamaño del corpus (2.877 documentos), fue necesario adaptar el proceso de entrada de datos a las limitaciones de contexto de los modelos. En particular:

- Se extrajeron todos los abstracts del corpus y se almacenaron en archivos de texto;
- los abstracts fueron fragmentados en subconjuntos de tamaño manejable cuando el modelo no admitía la totalidad del corpus;
- se observó que algunos modelos no eran capaces de procesar grandes volúmenes de texto de manera consistente, incluso tras la fragmentación.

Estas diferencias permitieron identificar variaciones significativas en la calidad, estabilidad y coherencia ontológica generada por cada modelo.

Análisis de consenso y refinamiento ontológico

A partir de las ontologías generadas por los distintos LLMs, se realizó un análisis comparativo orientado a identificar patrones comunes, divergencias y vacíos conceptuales. Este análisis de

consenso permitió: consolidar clases nucleares como *climate_hazard* y *adaptation_measure*; armonizar definiciones, jerarquías y sinónimos; y detectar la ausencia sistemática de ciertas dimensiones relevantes.

Como resultado de este proceso, se decidió ampliar la ontología incorporando de forma explícita clases relacionadas con impactos climáticos, sectores y activos, localización geográfica, y grupos sociales y poblaciones vulnerables.

Ampliación de clases y jerarquías

A partir del análisis iterativo del corpus y de la comparación entre las ontologías inducidas por los distintos modelos de lenguaje, se identificó la necesidad de ampliar la ontología inicial mediante la incorporación y refinamiento de cuatro dimensiones conceptuales clave: (1) *location*, (2) *social_group*, (3) *climate_impact* y (4) *sector*. Estas dimensiones aparecen de forma recurrente en los documentos analizados y resultan fundamentales para representar adecuadamente el conocimiento sobre medidas de adaptación al cambio climático. La ampliación de estas clases tuvo como objetivo mejorar la expresividad semántica de la ontología, facilitar la normalización terminológica y permitir la formulación de consultas complejas que integren impactos climáticos, contextos espaciales, grupos sociales y sectores socioeconómicos. En los apartados siguientes se describen las ampliaciones realizadas.

Clase *location* y sus subclases

La clase *location* se introdujo como una entidad de alto nivel destinada a representar los distintos tipos de referencias espaciales presentes en el corpus. Esta clase agrupa no solo regiones administrativas, sino también contextos geográficos y climáticos relevantes para la adaptación al cambio climático. Se definió con sinónimos generales como *place*, *area*, *geographical area* y *region*, reflejando la variabilidad terminológica observada en los textos.

A partir de esta clase raíz, se agregaron cuatro subclases principales:

a) *European City*: se incorporó para modelar referencias explícitas a ciudades europeas, especialmente frecuentes en documentos procedentes de Climate-ADAPT. Estas entidades se modelaron como instancias individuales (por ejemplo, *Amsterdam*, *Barcelona*, *Madrid*, *Paris*, *Berlin*, entre otras), todas ellas subordinadas a la subclase *EuropeanCity*, que a su vez depende

de *urban area*. Esta decisión permite realizar consultas específicas a nivel urbano sin perder la generalidad de la estructura ontológica.

b) *Climate Region*: representa regiones definidas por características climáticas compartidas, ampliamente utilizadas en la literatura de adaptación. Se incluyeron instancias como *Mediterranean Region*, *Alpine Region*, *Atlantic Region*, *Continental Region*, *Nordic Region*, *Arctic Region*, *Boreal Region*, *Temperate Region* y *Subtropical Region*. Cuando fue pertinente, se incorporaron sinónimos explícitos (por ejemplo, *Mediterranean climate* o *polar region*), con el objetivo de capturar variantes terminológicas frecuentes sin duplicar conceptos.

c) *Geographic Context*: se definió para representar configuraciones físicas o geomorfológicas que condicionan tanto los impactos climáticos como las estrategias de adaptación. Entre las instancias incluidas se encuentran *island*, *archipelago*, *peninsula*, *delta*, *river basin*, *mountain*, *lowland*, *highland* y *valley*. En este nivel se introdujeron jerarquías adicionales, como el caso de *small island* como subclase de *island*, incorporando sinónimos como *SIDS* (*Small Island Developing States*), de uso habitual en los informes del IPCC.

d) *WorldRegion*: agrupa grandes regiones geográficas y climáticas de escala global, tales como *Africa*, *Asia*, *Europe*, *Americas*, así como categorías transversales como *Tropics*, *Arid Regions*, *Semi-arid Regions* y *Coastal Regions*. Esta subclase permite capturar generalizaciones espaciales frecuentes en estudios comparativos y evaluaciones globales de riesgo y adaptación.

Clase social_group y sus subclases

La clase *social_group* se incorporó para representar explícitamente grupos poblacionales y comunidades mencionadas en el corpus en relación con vulnerabilidad, exposición y capacidad adaptativa. Se definió como una entidad de alto nivel, con sinónimos como *population group* y *community*, reflejando el uso intercambiable de estos términos en la literatura.

Dentro de esta clase, se definió la subclase *VulnerableGroup*, destinada a agrupar colectivos identificados sistemáticamente como más expuestos o con menor capacidad de adaptación frente a los impactos climáticos. Esta subclase incluye sinónimos como *vulnerable population* y *at-risk group*. A partir de *VulnerableGroup*, se modelaron instancias específicas recurrentes en el corpus, entre ellas: *low-income population*, con sinónimos como *poor* o *economically disadvantaged*; *marginalized community*; *elderly people*, incluyendo variantes como *older adults* o *senior citizens*; *children*, con sinónimos como *youth* o *minors*; *informal settlement*, incorporando términos como *slum* y *deprived area*.

Esta estructuración permite representar de manera explícita la dimensión social de la adaptación climática y facilita consultas orientadas a equidad, justicia climática y vulnerabilidad diferencial.

Clase Location y la depuración de instancias geográficas

Originalmente, la clase *Location* incluía una subclase *EuropeanCity* con instancias específicas (Madrid, París, etc.). Sin embargo, las iteraciones con los LLMs revelaron una debilidad crítica: la tendencia de los modelos a clasificar erróneamente ciudades globales (como Tokio o Seúl) bajo el nodo europeo. Ante este riesgo de inconsistencia, se adoptó una decisión de diseño basada en la parsimonia: se eliminó la subclase *EuropeanCity* y sus instancias individuales. Se determinó que el grafo es capaz de localizar geográficamente los estudios mediante las clases topográficas y regionales existentes (*ClimateRegion*, *GeographicContext*, *WorldRegion*), evitando la inflación de nodos y los errores de clasificación geográfica de los modelos.

Dualidad semántica: Climate Impact vs. Adaptation Outcome

Uno de los hitos más significativos del refinamiento fue la separación explícita entre las consecuencias negativas del cambio climático y los resultados positivos de la adaptación. Esta distinción es vital para la capacidad de razonamiento del sistema GraphRAG. Se establecieron dos clases independientes bajo la entidad raíz:

- Impact (ClimateImpact): Categoriza exclusivamente fenómenos negativos (daños, pérdidas). Bajo esta lógica, términos como *mortality*, *water scarcity* o *crop failure* fueron reubicados aquí, tras ser identificados erróneamente como sectores en versiones previas.
- Outcome (AdaptationOutcome): Agrupa los beneficios derivados de las medidas de adaptación.

Esta separación permite definir relaciones unívocas: un Hazard causa (causes) un Impact, mientras que una AdaptationMeasure produce (results_in) un Outcome o reduce (reduces) un Impact.

Clase Sector: Estructura de sistemas estables

La clase Sector se rediseñó bajo un criterio de estabilidad sistémica. Se aplicó una regla estricta: un término solo se considera Sector si es un sistema que puede existir independientemente de los impactos y que puede ser sujeto de medidas o amenazas propias. Tras varias iteraciones, se consolidaron los siguientes subsectores y subclases:

- Urban System: *Infrastructure, Services, Governance*.
- Agriculture and Food: *Crop systems, Livestock, Food systems*.
- Water: *Resources, Supply/Distribution, Hydrological systems*.
- Health: *Public health, Healthcare systems*.
- Energy: *Production, Transmission, Electricity systems*.
- Infrastructure and Networks: *Transport (Road, Rail, Air, Port) y Telecommunication*.
- Ecosystems: *Forest, Wetland, Coastal, Mangrove, Urban, Freshwater, Marine*.

Este enfoque descartó términos como "seguridad alimentaria" o "enfermedades" de la clase Sector, trasladándolos a Impact, logrando así una ontología más limpia donde cada concepto ocupa su lugar según su rol funcional y no solo por su etiqueta lingüística.

Criterios de exclusión y tratamiento de conceptos abstractos

Durante la fase de armado de la ontología se identificaron diversos conceptos abstractos y cuantitativos recurrentes en el corpus, como *vulnerability*, *resilience*, efectividad, costes y reducciones porcentuales. Si bien estos conceptos son centrales en los marcos teóricos de la adaptación al cambio climático (por ejemplo, IPCC AR6), se optó por no modelarlos como clases ontológicas independientes, con el fin de evitar un exceso de abstracción y preservar la capacidad de razonamiento práctico del grafo.

En el caso de *vulnerability* y *resilience*, se decidió representarlos como propiedades semánticas de entidades existentes (*SocialGroup*, *Sector*, *Impact* o *AdaptationMeasure*) en lugar de introducirlos como nodos autónomos. Esta elección permite reflejar adecuadamente su carácter transversal y relacional, alineándose con la literatura científica, sin introducir relaciones vagas o difíciles de explotar computacionalmente.

De forma análoga, los valores cuantitativos y cualitativos relacionados con la efectividad de las medidas, los costes de implementación o la magnitud de la reducción de impactos se modelaron como propiedades asociadas a las entidades, complementadas por evidencia textual extraída de los resúmenes y fragmentos originales de los documentos. Este enfoque distingue entre una estructura ontológica estable, basada en relaciones semánticas claras, y la información contextual rica, que permanece anclada al texto fuente.

Finalmente, se decidió excluir explícitamente herramientas y metodologías técnicas (por ejemplo, *machine learning* o *digital twins*) del modelado ontológico, dado que el objetivo del grafo es representar conocimiento sobre impactos, contextos y medidas de adaptación al cambio climático, y no sobre los métodos analíticos empleados en los estudios. Esta delimitación contribuye a mantener el foco conceptual del modelo y a maximizar su utilidad para tareas posteriores de razonamiento y recuperación aumentada de información. En conjunto, estas decisiones permitieron construir una ontología expresiva, controlada y orientada al uso, adecuada tanto para el análisis conceptual como para su integración en un sistema de recuperación y generación de conocimiento basado en grafos.

Evolución y refinamiento de las relaciones ontológicas

El diseño de las relaciones ontológicas se abordó como un proceso iterativo, partiendo de una versión inicial propuesta por ChatGPT y refinándola progresivamente mediante comparaciones con esquemas alternativos, recomendaciones de modelos adicionales y validación empírica sobre el corpus. El objetivo fue lograr un conjunto de relaciones conceptualmente sólido, semánticamente preciso y adecuado para representar el flujo causal de la adaptación al cambio climático, así como su contextualización espacial, social y sectorial.

Versión inicial: relaciones nucleares y contextuales básicas

La versión inicial de la ontología se estructuró en torno a un núcleo mínimo de relaciones imprescindibles para capturar la lógica causal básica del dominio. En esta fase, se definió un flujo principal en el que los peligros climáticos (*ClimateHazard*) se relacionan con los impactos (*Impact*) mediante relaciones causales (*causes / leads to*), y estos impactos se vinculan con sectores, grupos sociales y localizaciones. Asimismo, las medidas de adaptación (*AdaptationMeasure*) se conectaron con los peligros, impactos, sectores, grupos sociales y localizaciones mediante relaciones como *addresses*, *targets* o *applied_in*.

Adicionalmente, se incorporaron relaciones consideradas de alto valor añadido, como *exposed_to* y *located_in*, con el objetivo de comenzar a representar explícitamente la exposición diferencial de los grupos sociales frente a los peligros climáticos. Si bien esta versión permitía una representación básica del dominio, presentaba limitaciones en términos de claridad semántica, direccionalidad del flujo causal y diferenciación entre relaciones de evento y relaciones de contexto.

Refinamiento estructural: separación entre flujo causal y relaciones auxiliares

En una segunda fase, se adoptó un esquema más fino que distinguía explícitamente entre relaciones de flujo causal principal y relaciones auxiliares u opcionales. Este enfoque permitió clarificar la lógica central del dominio, estructurando el conocimiento en torno a una secuencia conceptual clara:

ClimateHazard → *Impact* → *AdaptationMeasure* → *AdaptationOutcome*.

En este esquema se introdujeron relaciones como *triggers*, *addresses* y *produces*, que permitieron modelar de forma explícita la progresión desde la amenaza hasta el resultado de

adaptación. Paralelamente, se reorganizaron las relaciones espaciales, sociales y sectoriales como relaciones auxiliares, encargadas de contextualizar cada elemento del flujo principal sin interferir en su coherencia causal. Asimismo, se propusieron relaciones opcionales, como *cascadesTo* entre impactos o *exacerbates* entre peligros, destinadas a capturar fenómenos complejos como las cadenas de riesgo o las interacciones entre amenazas, manteniendo estas extensiones fuera del núcleo mínimo para preservar la simplicidad de la versión inicial de la ontología.

Versión definitiva: integración y validación empírica

La versión definitiva de las relaciones ontológicas integró los elementos más sólidos de las versiones anteriores y aplicó criterios adicionales de precisión semántica, consistencia ontológica y frecuencia de uso en el corpus. En esta etapa se consolidó la distinción entre dos grandes tipos de relaciones:

1. Relaciones de flujo o causales, que conectan eventos y procesos a lo largo de la cadena de adaptación climática.
2. Relaciones de contexto o anclaje, que sitúan dichos eventos en un marco espacial, social, sectorial y documental.

Dentro de las relaciones causales, se optó por el uso de *causes* en lugar de *triggers*, tras constatar que el verbo *causes* aparecía de forma significativamente más frecuente en el corpus analizado. No obstante, esta decisión se acompañó de una definición explícita que reconoce el carácter no determinista de la causalidad climática, alineándose así con el uso del término en ontologías de alto nivel. De esta manera, se incorporaron relaciones como *cascadesTo* entre impactos, definida como transitiva, con el fin de modelar cadenas de riesgo y efectos en cascada, especialmente relevantes en contextos de cambio climático.

En el ámbito social, se sustituyó la relación genérica *affects* por *burdens*, con el objetivo de capturar de manera más precisa la carga negativa y la presión socioeconómica que los impactos climáticos ejercen sobre determinados grupos sociales. Esta elección semántica permite una representación más directa de la vulnerabilidad y la injusticia climática, evitando ambigüedades asociadas a verbos excesivamente generales. Finalmente, se consolidó el eje espacial mediante relaciones diferenciadas como *occursIn* para peligros e impactos,

isImplementedIn para medidas de adaptación y *isLocatedIn* para grupos sociales, reconociendo las diferencias ontológicas entre eventos que ocurren y acciones que se implementan de forma deliberada. En conjunto, este proceso de refinamiento permitió construir un sistema de relaciones coherente, expresivo y alineado tanto con el corpus como con los objetivos del grafo de conocimiento, proporcionando una base sólida para el análisis de medidas de adaptación al cambio climático desde una perspectiva integrada.

Consideraciones metodológicas generales

La ampliación progresiva de estas clases responde a una estrategia incremental de diseño ontológico, en la que cada dimensión se formaliza únicamente cuando existe suficiente evidencia empírica en el corpus y coherencia con los objetivos del grafo de conocimiento. Este enfoque permite mantener un equilibrio entre cobertura conceptual y control semántico, evitando la introducción prematura de clases no suficientemente fundamentadas. Asimismo, la separación explícita de estas dimensiones facilita futuras extensiones de la ontología, así como su reutilización en otros contextos de análisis relacionados con la adaptación al cambio climático.

Visualización y validación

Las ontologías generadas en formato JSON fueron visualizadas mediante herramientas específicas como *Ontology Viewer Standalone Versión 3 y 4*. Para ello, fue necesario adaptar y normalizar los archivos generados por los LLMs, asegurando su compatibilidad con los visualizadores. La visualización permitió detectar inconsistencias estructurales, relaciones mal orientadas y jerarquías incorrectas, constituyendo una etapa adicional de validación cualitativa del modelo ontológico.

Síntesis de la fase

La Fase II permitió construir una ontología de adaptación al cambio climático basada en evidencia textual, combinando ingeniería de prompts, experimentación con LLMs y validación humana. El enfoque adoptado demostró que los modelos de lenguaje pueden ser utilizados como herramientas eficaces para el descubrimiento ontológico, siempre que se los integre dentro de un marco metodológico riguroso que priorice la trazabilidad, la parsimonia y el control humano.

La ontología resultante sienta las bases para la construcción del grafo de conocimiento y las tareas de análisis y visualización desarrolladas en las fases posteriores del trabajo. Esta se denominó de la siguiente manera, *Ontología_fusion_grupal_visualizar_V03_200126_final*, y el código del json está disponible en el *anexo I* y es compatible con *Ontology_viewer_Standalone_V4*.

Fase III: la alianza con los LLMs y la construcción del grafo

La Fase III corresponde a la etapa de construcción automática del grafo de conocimiento a partir del corpus científico, mediante técnicas de minería textual avanzadas y el uso experimental de Modelos de Lenguaje de Gran Escala (Large Language Models, LLMs). Esta fase constituye el paso de transformación entre el texto no estructurado y una representación formal, computable y navegable del conocimiento.

Enfoque general y rol de los LLMs

Los LLMs se emplearon como motores de extracción semántica, con el objetivo de identificar entidades y relaciones explícitamente mencionadas en el corpus y proyectarlas sobre una ontología previamente definida. Se trabajó con distintos modelos (ChatGPT, DeepSeek, Claude Y Gemini), lo que permitió comparar comportamientos, limitaciones y calidad de salida. Dado que los LLMs presentan fenómenos conocidos de *hallucination* y sobre-generación, se priorizó un enfoque de alta precisión y fuerte control ontológico, incluso a costa de sacrificar exhaustividad. Para ello, se diseñó un esquema de *prompt engineering* basado en dos principios:

- Schema-Guided Extraction: la ontología en formato JSON se utilizó como única fuente de verdad estructural. El modelo fue instruido explícitamente para no crear nuevas clases, relaciones ni tipos de nodos fuera de dicho esquema.
- Restricción semántica fuerte: el modelo solo podía extraer conceptos explícitamente mencionados en el corpus, y toda discrepancia con la ontología debía resolverse a favor de esta última.

El resultado esperado de cada ejecución era un grafo completo (nodos y aristas) serializado en un único objeto JSON, directamente utilizable por un visualizador de grafos independiente.

Diseño del prompt y control de la salida

El proceso de generación del grafo se estructuró mediante un prompt en dos mensajes:

1. Mensaje de rol: definía al modelo como un “Knowledge Graph Construction Engine” especializado en adaptación al cambio climático, estableciendo reglas estrictas de cumplimiento ontológico y precisión.
2. Mensaje de tarea: adjuntaba la ontología y el corpus, y detallaba de forma exhaustiva las reglas de creación de nodos, relaciones, consistencia del grafo y formato de salida.

Se incluyeron mecanismos explícitos de validación, como el campo `_validationStatus`, para marcar automáticamente los nodos que, aun estando presentes en el corpus, no contaban con respaldo ontológico suficiente. Esto permitió utilizar los errores no como fallos, sino como señales para refinar la ontología.

Limitaciones de contexto y segmentación del corpus

Uno de los principales inconvenientes detectados fue la limitación de contexto de los LLMs. El corpus completo no podía ser procesado en una sola llamada sin provocar fallos o respuestas incompletas.

Para resolver este problema, se adoptaron dos estrategias complementarias:

- segmentación del corpus: el corpus se dividió en varias partes (entre 3 y 6 fragmentos, según el modelo), generando subgrafos parciales que posteriormente fueron fusionados mediante scripts externos.
- síntesis intermedia del corpus (*plan B*): en algunos experimentos, se utilizó un LLM para generar primero un texto sintético (*corpus_synthesized*) que resumía patrones recurrentes (hazards, impactos, sectores, medidas y resultados de adaptación). Este texto condensado se empleó luego como entrada para la construcción del grafo. Por tal motivo, se diseñó un nuevo prompt llamado *PROMPT B_corpus_synthesized*, ubicado en el *Anexo I*. Esta

segunda estrategia mostró resultados especialmente prometedores, al reducir ruido, mejorar la coherencia semántica y facilitar la extracción de relaciones relevantes, aunque a costa de no explotar la totalidad de los abstracts originales. El json para visualizar el grafo se denomina *Grafo_DeepSeek_planB_sumupallabstracts_210126*, y podrá ser encontrado en el *Anexo I*.

Validación, errores recurrentes y refinamiento ontológico

La generación de grafos parciales permitió identificar patrones sistemáticos de error, que se convirtieron en insumos directos para la validación y mejora de la ontología. Entre los principales problemas detectados se encuentran:

- Creación errónea de instancias geográficas (por ejemplo, ciudades no europeas clasificadas como “European City”).
- Uso inconsistente o incorrecto de relaciones direccionales (por ejemplo, PART_OF, OCCURS_IN, IS_LOCATED_IN).
- Tratamiento inadecuado de sinónimos, donde el modelo generaba nodos nuevos en lugar de mapearlos a la clase principal.
- Aparición de conceptos instrumentales o tecnológicos (p. ej. *machine learning*, *digital twin*) que no aportaban valor ontológico y fueron deliberadamente excluidos.

Como respuesta, la ontología fue iterativamente refinada: se eliminaron clases problemáticas, se ajustaron relaciones ambiguas, se consolidaron sinónimos y se incorporaron únicamente aquellos conceptos nuevos que demostraban un uso recurrente y un valor semántico claro en el corpus (por ejemplo, *blue-green infrastructure* o *hurricane*). De esta manera, se ha logrado una versión del grafo conceptual considerada estable y suficientemente completa desde el punto de vista estructural. Esta se denomina *Grafo_final_6blocks_merged_definitivo_DeepSeek_250126* y se encuentra en el *Anexo I*.

Este proceso confirma que la ontología no es un artefacto estático, sino un objeto vivo, que se co-construye en diálogo constante con los datos y los modelos.

Estado actual y carácter exploratorio de la fase

En el momento de redacción de este trabajo, la Fase III se encuentra en desarrollo activo. Los grafos generados deben entenderse como prototipos funcionales, utilizados para evaluar decisiones metodológicas, comportamiento de los modelos y adecuación de la ontología. Lejos de considerarse una debilidad, este carácter exploratorio constituye uno de los principales aportes del trabajo: demuestra de forma empírica los desafíos reales de aplicar LLMs a la construcción de grafos de conocimiento científicos, y subraya la necesidad de combinar automatización, control humano y validación iterativa. En esta instancia y proceso de obtención de un grafo adecuado, se han obtenido dos grafos. El primero se ha llamado *Grafo_final_merged_enriched_abstracts_250126_txt1*, 2, 3, donde se ha logrado incluir abstracts y el posterior se ha llamado *final_graph_enriched_metadata_clean_260126.json*.

Estrategias de enriquecimiento semántico y evidencia textual

Una vez obtenidos los grafos de conocimiento estructurales (nodos y relaciones), se exploró una línea experimental adicional orientada a enriquecer el grafo con evidencia textual explícita, con el objetivo de vincular cada entidad y cada relación con fragmentos literales del corpus que justificaran su existencia. Esta estrategia buscaba aproximarse a un grafo de conocimiento *evidence-grounded*, en el que cada afirmación pudiera ser trazada directamente a un texto científico concreto.

Para ello, se diseñó un prompt específico que instruía al modelo para actuar como un evaluador estricto, encargado de añadir “sin modificar la estructura existente” un bloque de evidencia a cada nodo y relación del grafo. Dicho bloque debía incluir: (i) un *snippet* textual literal extraído del corpus, (ii) una breve justificación explicativa y (iii) un nivel de confianza cualitativo (alto, medio o bajo). El diseño del prompt imponía restricciones explícitas destinadas a minimizar la alucinación: prohibición de parafrasear, obligación de copiar texto literal y asignación de confianza baja en ausencia de soporte textual claro.

El prompt empleado fue el siguiente:

You are an evaluation and evidence-extraction model acting as a strict judge. You are given a knowledge graph in JSON format... (...) All snippets MUST be copied verbatim from the provided text. If no clear textual support exists, set snippet to null and confidence to "low". (...) Return ONLY the enriched graph JSON.

Este prompt se denominó *PROMPT C_snippet, evidence, confidence*, se encuentra en *Anexo I*. Este enfoque se probó tanto para nodos como para relaciones, así como en versiones reducidas del prompt centradas exclusivamente en nodos, con el fin de reducir la complejidad de la tarea.

Limitaciones técnicas y fragmentación del proceso

En la práctica, la aplicación de esta estrategia encontró limitaciones técnicas significativas. El tamaño del grafo resultante (superior a 40 MB en algunas versiones) y la longitud acumulada de las referencias textuales impidieron procesar el grafo completo en una sola ejecución, incluso utilizando modelos con ventanas de contexto amplias.

Para mitigar este problema, se implementó una fragmentación del grafo en subconjuntos más pequeños (bloques de aproximadamente 40–45 nodos), preservando únicamente las relaciones internas a cada bloque. Esta segmentación permitió ejecutar el proceso de enriquecimiento de forma parcial, aunque introdujo nuevos desafíos relacionados con la pérdida de contexto global y la coherencia entre subgrafos.

Se ensayaron múltiples combinaciones de modelos y entornos: LLMs comerciales (ChatGPT, Gemini), modelos abiertos ejecutados localmente y pipelines híbridos con scripts en Python para la división, procesamiento y posterior fusión de los subgrafos. Sin embargo, incluso en los escenarios más controlados, los resultados fueron inconsistentes: en algunos casos, el modelo devolvía grafos vacíos; en otros, añadía evidencia incompleta, no verificable o con fragmentos que no podían validarse automáticamente como substrings literales del corpus.

Consolidación del grafo y resolución de desconexiones

Tras los experimentos iniciales de enriquecimiento, se obtuvo una primera versión integral del grafo denominada *final_graph_with_evidence_280126*, se podrá encontrar en *Anexo 01*. Si bien este archivo logró por primera vez unificar entidades, relaciones y evidencia textual (snippets y justificaciones), el análisis topológico mediante herramientas de visualización reveló un problema crítico de conectividad: la presencia de 22 islas semánticas desconectadas del componente principal.

Estas islas representaban nodos que, aunque válidos según el corpus, no poseían vínculos explícitos con la red central de conocimientos. Tras una inspección manual, se categorizaron estas desconexiones en dos tipos. Por un lado, casos de estudio muy específicos que no establecían puentes con los conceptos generales de la ontología. Por el otro, sinonimia y redundancia, conceptos que el modelo extrajo como nuevos pero que, semánticamente, ya estaban representados en la red principal bajo otras etiquetas.

Lejos de considerarse un fallo del modelo, este resultado permitió realizar un diagnóstico final de la estructura de datos. Para resolver la fragmentación y asegurar un grafo unificado y navegable, se procedió a una etapa de limpieza y refinamiento ontológico.

Obtención del grafo final

La consolidación definitiva se realizó mediante un proceso híbrido que combinó la ejecución de scripts de limpieza de datos con un ajuste manual de la ontología. Este proceso se estructuró en tres pasos:

1. Podado de Islas: Se descartaron las instancias aisladas que no aportaban valor sistémico al flujo de conocimiento, priorizando la densidad de relaciones sobre la cantidad de nodos.
2. Fusión Semántica: Los sinónimos detectados en las islas se integraron en las clases existentes de la ontología, lo que resultó en la versión actualizada *OntologADa_fusion_grupal_visualizar_V04_290126*. Esta se encuentra en el *Anexo I, Fase II*, bajo el título “*Versión actualizada ontología*”.

3. Validación de Conectividad: Se generó el archivo *Graph_final_with_evidence_290126*, el cual constituye el artefacto final de esta fase. Se puede visualizar en *Anexo I, fase III, “Grafo final con referencias y sin islas”*.

Este grafo final no solo es estructuralmente sólido y conexo, sino que cumple con el objetivo de ser un grafo de conocimiento basado en evidencia (evidence-grounded). Cada una de sus aristas y nodos cuenta con el respaldo de fragmentos textuales literales del corpus, justificación semántica y niveles de confianza cualitativos. Con este hito, se da por finalizada la Fase III, disponiendo de una base de conocimiento computable lista para la fase de explotación y consultas mediante GraphRAG.

Fase IV: Experimentos con Retrieval-Augmented Generation (GraphRAG)

Objetivo general de la fase experimental

La Fase 4 tiene como objetivo principal evaluar empíricamente el funcionamiento, la robustez y el valor analítico del Knowledge Graph construido en las fases previas, mediante su integración en un sistema de *Retrieval-Augmented Generation* (RAG) con búsqueda estructural basada en grafos (*GraphRAG*).

A diferencia de las fases anteriores centradas en la recopilación de datos, el diseño ontológico y la construcción del grafo, esta fase adopta una perspectiva experimental, orientada a responder a la siguiente cuestión metodológica:

¿hasta qué punto la estructura del Knowledge Graph habilita un razonamiento más profundo, contextual y causal en comparación con enfoques tradicionales de recuperación de información basados en texto?

Para responder a esta pregunta, se diseñó un conjunto de experimentos controlados que permiten comparar distintos mecanismos de recuperación (RAG tradicional frente a GraphRAG) manteniendo constantes tanto la pregunta de investigación como los modelos de lenguaje utilizados. De este modo, se aísla el impacto de la estructura del conocimiento como variable explicativa central.

Selección del fenómeno climático y delimitación temática

Como punto de partida, se acordó seleccionar un fenómeno climático concreto (*hazard*) dentro de los contemplados por la plataforma Climate-ADAPT, concretamente inundaciones, sequías u olas de calor. Esta selección responde a la necesidad de trabajar con un fenómeno suficientemente representado en el corpus, con impactos bien documentados y con claras implicaciones sociales y territoriales.

En este trabajo se optó por el fenómeno de las olas de calor (*heatwaves*), debido a su creciente frecuencia e intensidad en Europa, así como a su carácter transversal, que permite analizar de forma integrada dimensiones climáticas, urbanas, socioeconómicas y de salud pública. La elección de este fenómeno resulta especialmente adecuada para la validación de un Knowledge Graph, ya que los impactos de las olas de calor no se distribuyen de manera homogénea, sino que afectan de forma diferencial a distintos grupos sociales en función de factores estructurales y contextuales.

Formulación de la pregunta de investigación

Con el fin de evitar sesgos en la formulación de la pregunta y garantizar su relevancia analítica, se solicitó a varios modelos de lenguaje externos (LLMs) la generación de posibles preguntas de investigación relacionadas con el fenómeno seleccionado. A partir de este conjunto de propuestas, se eligió la siguiente pregunta como eje de los experimentos:

“Which vulnerable social groups are most severely affected by heatwaves, and what specific socioeconomic factors exacerbate their exposure?”

Esta pregunta cumple varias funciones clave dentro del diseño experimental. En primer lugar, no puede resolverse mediante la consulta de un único documento, ya que requiere integrar información dispersa sobre impactos climáticos, características sociales y determinantes socioeconómicos. En segundo lugar, exige razonamiento relacional y causal, ya que no se limita a identificar grupos vulnerables, sino que solicita explicar los factores que intensifican su exposición. Por último, la pregunta presenta múltiples niveles de profundidad,

permitiendo evaluar si el sistema es capaz de descomponer la vulnerabilidad de cada grupo en factores específicos y de establecer conexiones indirectas a través del grafo.

Entorno experimental y configuración del sistema GraphRAG

Los experimentos se llevaron a cabo utilizando el *notebook Clima GraphRAG*, proporcionado como parte del entorno metodológico del curso. Este *notebook* se encuentra en el *Anexo I*, y permite integrar el Knowledge Graph en un sistema de recuperación estructural y generar prompts especializados para modelos de lenguaje externos. Una característica central del entorno es el uso de una plantilla experta (*expert template*), que empaqueta la información recuperada del grafo en un prompt estructurado. Esta plantilla obliga explícitamente al modelo de lenguaje a triangular evidencias procedentes de distintos nodos, utilizar relaciones explícitas del grafo, articular razonamiento causal y contextual y citar las fuentes asociadas a los nodos recuperados.

Para garantizar la comparabilidad de los resultados, todos los experimentos se ejecutaron con la misma configuración de parámetros:

- `top_k = 5`, correspondiente al número de documentos iniciales recuperados
- `context_k = 3`, que controla la expansión de contexto
- `hops = 2`, que determina el número de saltos en el grafo y, por tanto, el alcance causal de la búsqueda

Esta configuración permite explorar relaciones indirectas sin introducir un nivel excesivo de ruido semántico, manteniendo un equilibrio entre profundidad y precisión.

Guía de validación del knowledge graph

La evaluación del sistema se realizó siguiendo la *Guía de Validación*: “¿Funciona nuestro Grafo?”, que propone un conjunto de pruebas complementarias orientadas a evaluar

distintos aspectos del rendimiento del Knowledge Graph. Esta guía se encuentra en *Anexo I*. Estas pruebas no buscan medir métricas cuantitativas tradicionales, sino analizar cualitativamente la capacidad explicativa y relacional del sistema. Las pruebas aplicadas fueron las siguientes:

1. Pregunta de control (*Litmus Test*)
2. Protocolo de comparación A/B
3. Prueba de estrés de vocabulario
4. Auditoría de relaciones (*Reality Check*)

Adicionalmente, se realizaron comparaciones utilizando distintos LLMs externos, con el objetivo de comprobar si los resultados observados dependen del modelo de lenguaje o del mecanismo de recuperación. Todos los experimentos se encuentran en *Anexo I, FASE IV. Experimentos con Retrieval-Augmented Generation (GraphRAG), Tests RAG. M. Ayelén Cura.*

Test 1: pregunta de control (Litmus Test)

La primera prueba consistió en evaluar si la pregunta de investigación seleccionada permite validar el carácter estructural del Knowledge Graph. Para ello, se analizó si la consulta puede resolverse únicamente mediante recuperación textual o si requiere necesariamente integrar múltiples conceptos y relaciones.

La pregunta obliga al sistema a conectar al menos tres dimensiones distintas:
(i) el fenómeno climático (olas de calor),

(ii) los grupos sociales vulnerables, y

(iii) los factores socioeconómicos que exacerban la exposición.

La respuesta adecuada requiere relacionar grupos como personas mayores, trabajadores expuestos al exterior, hogares de bajos ingresos o personas con enfermedades crónicas con variables como ingresos, calidad de la vivienda, tipo de empleo y acceso a servicios de salud. Esta integración evidencia que el Knowledge Graph representa conocimiento relacional y no únicamente información fragmentada.

Test 2: protocolo de comparación A/B con Gemini Flash 2.0

El segundo test se diseñó como un experimento comparativo entre dos escenarios:

- Escenario A: RAG tradicional con búsqueda plana
- Escenario B: GraphRAG con búsqueda estructural

Ambos escenarios utilizan la misma pregunta y el mismo modelo de lenguaje (Gemini Flash 2.0), aislando así el efecto del mecanismo de recuperación. En el Escenario A, la respuesta generada presenta una organización principalmente enumerativa, con relaciones causales simples y una integración limitada del contexto. Los factores socioeconómicos se describen de manera aislada, sin una articulación sistémica clara. En contraste, el Escenario B muestra una mayor profundidad analítica. La expansión estructural del grafo permite incorporar conceptos no explicitados en la pregunta, así como establecer conexiones indirectas entre condiciones urbanas, factores socioeconómicos e impactos en la salud. El resultado es una explicación relacional que representa redes de vulnerabilidad complejas.

Test 3: Prueba de estrés de vocabulario

Con el objetivo de evaluar la robustez terminológica del sistema, se sustituyó el término “heatwaves” por el sinónimo “extreme heat” en la pregunta de control, manteniendo constante el resto de la configuración. Los resultados muestran una recuperación idéntica de documentos y cadenas causales, así como respuestas coherentes que identifican los mismos grupos vulnerables y factores exacerbantes. Este comportamiento confirma que la búsqueda semántica basada en *embeddings* mapea adecuadamente variaciones léxicas hacia los nodos estructurados del Knowledge Graph.

Test 4: auditoría de relaciones (Reality Check)

La auditoría de relaciones se realizó mediante una comparación A/B entre búsqueda plana y GraphRAG, con el objetivo de evaluar la precisión semántica de las relaciones

utilizadas en el razonamiento. Si bien GraphRAG demuestra una capacidad claramente superior para articular cadenas causales y contextuales, la auditoría revela la presencia de relaciones excesivamente genéricas, como *EXPERIENCES*. Estas relaciones, aunque funcionales desde el punto de vista técnico, reducen el poder explicativo del grafo y evidencian la necesidad de un refinamiento ontológico. Este resultado pone de manifiesto que el rendimiento de GraphRAG depende críticamente de la calidad semántica de las relaciones, y no únicamente de la densidad del grafo.

Comparaciones con LLMs externos

Finalmente, se realizaron comparaciones utilizando distintos LLMs externos (ChatGPT-4.1, DeepSeek y DeepSeek en modo *deepthink*), manteniendo constante la pregunta y el mecanismo de recuperación. En todos los casos, el patrón observado es consistente: el RAG tradicional produce respuestas correctas pero esencialmente extractivas, mientras que GraphRAG habilita razonamiento causal, expansión conceptual y contextualización espacial. La aparición de nuevos grupos vulnerables en el Escenario B refuerza la hipótesis de que el valor añadido reside en la estructura del conocimiento y no en el modelo de lenguaje.

Síntesis y aportes de la fase experimental

En conjunto, los experimentos realizados demuestran que el uso de GraphRAG permite transformar la recuperación de información en un proceso explicativo y relacional. La fase experimental valida tanto el diseño conceptual del Knowledge Graph como su capacidad para soportar análisis complejos sobre vulnerabilidad social frente a riesgos climáticos. Al mismo tiempo, los resultados evidencian limitaciones asociadas a la calidad de las relaciones ontológicas, lo que señala líneas claras de mejora para trabajos futuros.

DISCUSIÓN DE RESULTADOS

Introducción a la discusión

La presente sección tiene como objetivo interpretar críticamente los resultados obtenidos en la Fase 4 del trabajo, evaluando su significado metodológico y conceptual en relación con el uso de *Retrieval-Augmented Generation* basado en grafos (*GraphRAG*) para el análisis de vulnerabilidad social frente a riesgos climáticos. A diferencia de la sección de resultados, centrada en la descripción sistemática de los distintos tests realizados, esta discusión aborda las implicaciones de dichos resultados, sus fortalezas, limitaciones y su contribución al ámbito de especialización.

En particular, se analiza hasta qué punto el Knowledge Graph construido a partir de Climate-ADAPT y su integración en un sistema GraphRAG permite superar las limitaciones de los enfoques tradicionales de recuperación de información basados en texto, y en qué medida habilita formas de razonamiento más alineadas con enfoques sistémicos, causales y contextuales propios de los estudios sobre adaptación al cambio climático y justicia climática.

Validez del Knowledge Graph como estructura de conocimiento

Uno de los principales aportes de los resultados obtenidos es la confirmación empírica de que el Knowledge Graph no actúa simplemente como un repositorio estructurado de información, sino como una infraestructura cognitiva capaz de sostener razonamiento relacional. El *Litmus Test* demuestra que la pregunta de investigación seleccionada no puede resolverse mediante recuperación directa de fragmentos textuales, sino que requiere la integración de múltiples dimensiones del conocimiento: fenómeno climático, grupos sociales vulnerables y factores socioeconómicos exacerbantes.

Este resultado es especialmente relevante desde el punto de vista metodológico, ya que valida el supuesto central del trabajo: que el valor de un Knowledge Graph no reside únicamente en la organización de datos, sino en su capacidad para representar dependencias, interacciones y relaciones causales complejas. La correcta resolución de la pregunta de control indica que el grafo captura conocimiento estructural, y no únicamente asociaciones

superficiales entre conceptos. Además, la posibilidad de descomponer la vulnerabilidad de distintos grupos sociales en factores específicos pone de manifiesto que el grafo permite operar a distintos niveles de granularidad, una característica fundamental para el análisis de riesgos climáticos, donde los impactos dependen de la interacción entre factores individuales, sociales y territoriales.

Comparación entre RAG tradicional y GraphRAG: implicaciones metodológicas

Los resultados de los protocolos de comparación A/B constituyen uno de los ejes centrales de esta discusión. En todos los experimentos realizados, tanto con Gemini Flash como con ChatGPT-4.1 y DeepSeek, se observa un patrón consistente: el RAG tradicional genera respuestas correctas, coherentes y alineadas con la literatura, pero fundamentalmente extractivas y lineales. El comportamiento observado es esperable, dado que la búsqueda plana se limita a recuperar fragmentos textuales relevantes y a sintetizarlos sin explorar relaciones implícitas o indirectas. En este contexto, el razonamiento del LLM se apoya casi exclusivamente en la información explícita de los documentos recuperados, lo que restringe la profundidad analítica del resultado. En contraste, el GraphRAG muestra una capacidad sistemática para generar respuestas más profundas, contextualizadas y explicativas. La búsqueda estructural permite expandir el contexto más allá de los términos explícitos de la pregunta, incorporando nodos relacionados a múltiples saltos de distancia y articulando cadenas causales complejas. Este comportamiento no depende del modelo de lenguaje utilizado, lo que refuerza la conclusión de que el valor añadido reside en el mecanismo de recuperación y no en las capacidades intrínsecas del LLM. Desde una perspectiva metodológica, estos resultados sugieren que GraphRAG no debe entenderse como una simple mejora incremental del RAG tradicional, sino como un cambio de paradigma en la recuperación de información, en el que la estructura del conocimiento desempeña un papel activo en la generación de significado.

Razonamiento causal y enfoque sistémico

Uno de los aspectos más relevantes que emergen de los resultados es la capacidad de GraphRAG para habilitar razonamiento causal y sistémico, en contraposición al razonamiento lineal característico del RAG tradicional. En los escenarios GraphRAG, las respuestas no se limitan a enumerar grupos vulnerables y factores socioeconómicos, sino que articulan redes de

vulnerabilidad en las que interactúan condiciones urbanas, infraestructuras, dinámicas socioeconómicas e impactos en la salud. Este tipo de razonamiento es especialmente pertinente en el ámbito de la adaptación al cambio climático, donde los impactos no pueden entenderse de forma aislada, sino como el resultado de múltiples procesos interrelacionados. La capacidad del sistema para identificar consecuencias indirectas y mecanismos intermedios refleja una aproximación más cercana al pensamiento sistémico, ampliamente reconocido como necesario para abordar problemas climáticos complejos. Asimismo, la emergencia de nuevos grupos vulnerables en los escenarios GraphRAG, ausentes en las respuestas generadas mediante búsqueda plana, pone de manifiesto que el razonamiento relacional permite detectar vulnerabilidades que no son evidentes a partir de una lectura superficial de la literatura. Este resultado tiene implicaciones importantes para la investigación aplicada y la formulación de políticas públicas, ya que sugiere que los enfoques basados en grafos pueden contribuir a una identificación más completa de riesgos y desigualdades.

Robustez semántica y estabilidad conceptual

La prueba de estrés de vocabulario aporta evidencia adicional sobre la solidez del sistema. El hecho de que la sustitución de “*heatwaves*” por “*extreme heat*” no altere ni la recuperación de documentos ni las cadenas causales identificadas indica que el sistema es robusto frente a variaciones léxicas del lenguaje natural. Este resultado es particularmente relevante en contextos reales de uso, donde las consultas de los usuarios pueden formularse de múltiples maneras. La capacidad de mapear distintos términos a los mismos nodos conceptuales del Knowledge Graph demuestra que la combinación de embeddings semánticos y estructura ontológica es eficaz para preservar la coherencia conceptual del sistema. Desde una perspectiva más amplia, esta robustez semántica refuerza la validez del diseño ontológico y confirma que el grafo no depende de una formulación rígida del vocabulario, sino que opera sobre representaciones conceptuales más abstractas.

Limitaciones evidenciadas por la auditoría de relaciones

A pesar de los resultados positivos, la auditoría de relaciones pone de relieve limitaciones importantes que deben ser consideradas críticamente. En particular, la presencia de relaciones excesivamente genéricas, como *EXPERIENCES*, reduce la capacidad explicativa del grafo y puede introducir ambigüedad en el razonamiento. Este hallazgo subraya que la

eficacia de GraphRAG depende de manera crítica de la calidad semántica de las relaciones, y no únicamente de la cantidad de nodos o de la densidad del grafo. Un grafo con relaciones poco específicas puede facilitar la expansión del contexto, pero al mismo tiempo limitar la interpretabilidad y el rigor analítico de las respuestas generadas. Desde el punto de vista metodológico, esta limitación no invalida los resultados obtenidos, sino que señala una línea clara de mejora: la necesidad de refinar la ontología de relaciones y de aplicar mecanismos de control de calidad más estrictos durante la fase de extracción. Este aspecto es especialmente relevante en dominios complejos como el climático, donde las relaciones causales y contextuales son fundamentales para una interpretación correcta de los datos.

Implicaciones para el uso de LLMs en análisis climático

Otro resultado relevante de esta investigación es la constatación de que las diferencias observadas entre los escenarios A y B se mantienen constantes al cambiar de modelo de lenguaje externo. Tanto ChatGPT-4.1 como DeepSeek, en sus distintas configuraciones, muestran patrones de comportamiento similares cuando se controla el mecanismo de recuperación. Este hallazgo refuerza la idea de que el principal cuello de botella en el uso de LLMs para análisis climático no es la capacidad lingüística del modelo, sino la forma en que se estructura y recupera el conocimiento. En este sentido, GraphRAG se presenta como una estrategia eficaz para alinear el razonamiento de los LLMs con marcos analíticos más rigurosos y transparentes. Además, la posibilidad de trazar cada afirmación a nodos y relaciones concretas del grafo mejora la interpretabilidad del sistema, un aspecto clave en contextos académicos y de apoyo a la toma de decisiones.

CONCLUSIONES

Este trabajo demuestra que la integración de un *Knowledge Graph* en un sistema de *Retrieval-Augmented Generation* basado en grafos constituye una aportación metodológica relevante para el análisis de vulnerabilidad social frente a riesgos climáticos.

A través de una serie de experimentos controlados, se evidenció que GraphRAG superó sistemáticamente a los enfoques tradicionales de recuperación de información en términos de profundidad analítica, razonamiento causal y contextualización sistémica. El valor añadido de GraphRAG residió en la reconfiguración del espacio de recuperación del conocimiento, que permite a los LLMs operar sobre estructuras conceptuales explícitas y relaciones semánticas bien definidas.

Desde el punto de vista del ámbito de especialización, la adaptación al cambio climático y el análisis de vulnerabilidad social, los resultados obtenidos fueron significativos. El enfoque GraphRAG permitió capturar y analizar la naturaleza multidimensional de la vulnerabilidad frente a fenómenos como las olas de calor, integrando factores climáticos, socioeconómicos, urbanos y de salud. Esta capacidad de articular razonamiento sistémico y causal resulta coherente con los enfoques contemporáneos de justicia climática, que enfatizan la necesidad de comprender cómo las desigualdades estructurales condicionan la exposición y la capacidad adaptativa de distintos grupos sociales. En este sentido, el *Knowledge Graph* no solo actuó como una herramienta técnica, sino como un marco conceptual que hace explícitas dichas desigualdades.

Finalmente, este trabajo pone de manifiesto que el desarrollo de sistemas de análisis basados en grafos requiere un equilibrio cuidadoso entre cobertura y precisión semántica. Si bien *GraphRAG* demuestra un gran potencial para habilitar razonamiento profundo, su eficacia depende de la calidad ontológica del grafo y, en particular, de la especificidad de las relaciones.

Como línea futura, se plantea la necesidad de refinar las ontologías de relaciones y de explorar mecanismos automáticos y semiautomáticos de validación semántica. Asimismo, la metodología propuesta es extensible a otros *hazards* climáticos, lo que abre la puerta a análisis comparativos y a aplicaciones prácticas en el diseño de políticas de adaptación.

En conclusión, este trabajo confirma que los sistemas GraphRAG constituyen una herramienta prometedora para transformar grandes volúmenes de información climática en conocimiento estructurado, interpretable y accionable, contribuyendo de manera significativa al avance metodológico en el estudio de la adaptación al cambio climático.

Bibliografía (formato APA)

Gruber, T. R. (1993). *A translation approach to portable ontology specifications*. Knowledge Acquisition, 5(2), 199–220. <https://doi.org/10.1006/knac.1993.1008>

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-T., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). *Retrieval-augmented generation for knowledge-intensive NLP tasks*. Advances in Neural Information Processing Systems, 33, 9459–9474.

Hogan, A., Blomqvist, E., Cochez, M., d’Amato, C., de Melo, G., Gutiérrez, C., Kirrane, S., Neumaier, S., Polleres, A., Navigli, R., & others. (2021). *Knowledge graphs*. ACM Computing Surveys, 54(4), 1–37. <https://doi.org/10.1145/3447772>

Anexo I

Fase I:

- Notebook 01 corpus clima taxonomía ampliada.ipynb

Fase II:

- Prompt Debug
- Ontología fusion grupal visualizar V03 200126 final

Versión actualizada Ontología:

- OntologADa fusion grupal visualizar V04 290126.

Fase III:

- Grafo DeepSeek planB sumupallabstracts 210126
- Grafo final 6blocks merged definitivo DeepSeek 250126

- Prompt A construcción grafo
- PROMPT B corpus synth sized
- PROMPT C snippet, evidence, confidence

Mejores grafos obtenidos, pero parcialmente completos:

- Grafo final merged enriched abstracts 250126 txt1, 2, 3
- final graph enriched metadata clean 260126.json

Grafos con referencias y 22 islas:

- final graph with evidence 280126

Grafo final con referencias y sin islas:

- Graph_final_with_evidence_290126

FASE IV. Experimentos con Retrieval-Augmented Generation (GraphRAG):

- Notebook GraphRag
- Guía de Validación: ¿Funciona nuestro Grafo?
- Tests RAG. M. Ayelén Cura